Political Data Science

Lektion 2:

R Workshop I: Explore

Undervist af Jesper Svejgaard, foråret 2018 Institut for Statskundskab, Københavns Universitet github.com/jespersvejgaard/PDS

I dag

- 1. Opsamling fra sidst
- 2. Overblik
- 3. Eksamensdatoer
- 4. Workflow i R
- 5. Styleguide
- 6. Highlights fra pensum
- 7. Workshop
- 8. Vigtigste pointer fra i dag
- 9. Næste gang

1. Opsamling fra sidst

- Hvad var de vigtigste pointer fra sidst?
- · Gennemgang af opgaver (se 01_script.R på GitHub)

2. Overblik

- 1. Intro til kurset og R
- 2. R Workshop I: Explore
- 3. R Workshop II: Import, tidy, transform
- 4. R Workshop III: Programmering & Git
- 5. Web scraping & API
- 6. Tekst som data
- 7. Visualisering
- 8. GIS & spatiale data
- 9. Estimation & prædiktion
- 10. Superviseret læring I
- 11. Superviseret læring II
- 12. Usuperviseret læring
- 13. Refleksioner om data science
- 14. Opsamling og eksamen

3. Eksamensdatoer

- · 28/05-18: Frist første indlevering
- · 31/05-18: Her får man at vide, hvis man ikke er bestået første indlevering
- 05/06-18: Frist anden indlevering
- · 07/06-18: Her får man at vide, hvis man ikke er bestået anden indlevering
- 11/06-18: Frist tredje indlevering

4. Workflow i R

- · At kode: Scripts vs. konsollen
- · At gemme: Scripts vs. environment
- Funktioner
- · Musen:(
- Brug genveje:
 - run: cmd+enter / ctrl+enter
 - run, but stay: option+enter / alt+enter
 - rerun script: cmd+shift+s / ctrl+shift+s
 - pipe: cmd+shift+m / ctrl+shift+m
 - kommentér: cmd+shift+c / ctrl+shift+c
 - gem, fortryd, kopier, sæt ind etc
 - se flere her

5. Styleguide

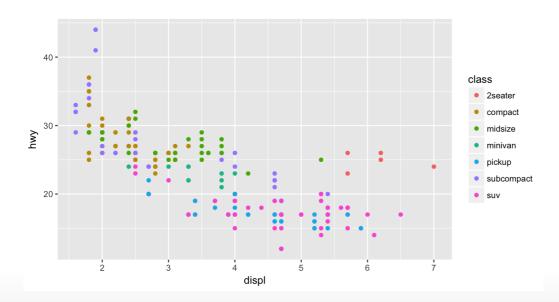
- Phil Karlton
- Navngivning
 - alllowercase
 - period.separated
 - underscore_separated
 - lowerCamelCase, UpperCamelCase
 - vigtigst: konsistens!
- Dokumentation af kode
- Styleguides
 - Hadley Wickham's style guide
 - Google's R style guide

ggplot2

```
## # A tibble: 4 x 11
##
    manufacturer model displ year
                                  cyl trans
                                                  drv
                                                       cty
                                                             hwy
##
          <chr> <chr> <dbl> <int> <int>
                                      <chr> <int> <int> <chr>
## 1
           audi
                   a4
                       1.8 1999
                                        auto(15)
                                                   f
                                                                    р
## 2
           audi
                   a4
                       1.8 1999
                                    4 manual(m5)
                                                        21
                                                             29
                                                                    р
## 3
           audi
                   a4 2.0 2008
                                    4 manual(m6)
                                                        20
                                                                    р
## 4
           audi
                   a4
                       2.0 2008
                                        auto(av)
                                                             30
                                                                    р
## # ... with 1 more variables: class <chr>
```

ggplot2

```
ggplot(data = mpg, aes(x = displ, y = hwy, color = class)) +
  geom_point()
```



ggplot2

Hvad er forskellen mellem nedenstående?

```
ggplot(data = mpg, aes(x = displ, y = hwy)) +
  geom_point() +
  geom_smooth()

ggplot(data = mpg) +
  geom_point(aes(x = displ, y = hwy)) +
  geom_smooth(aes(x = displ, y = hwy))
```

filter()

```
mpg_1999 <- filter(mpg, year == 1999)
print(mpg_1999)</pre>
```

```
## # A tibble: 117 x 11
##
     manufacturer
                              model displ year
                                                  cyl trans
                                                                  drv
                              <chr> <dbl> <int> <int>
##
            <chr>
                                                          <chr> <chr>
##
   1
             audi
                                 a4
                                      1.8 1999
                                                       auto(15)
                                                                    f
##
             audi
                                 a4
                                      1.8
                                           1999
                                                    4 manual(m5)
##
             audi
                                 a4
                                      2.8 1999
                                                       auto(15)
##
             audi
                                 a4
                                      2.8
                                           1999
                                                    6 manual(m5)
##
   5
             audi
                          a4 quattro
                                      1.8
                                           1999
                                                    4 manual(m5)
##
             audi
                          a4 quattro
                                      1.8 1999
                                                       auto(15)
##
             audi
                                      2.8
                          a4 quattro
                                          1999
                                                       auto(15)
##
             audi
                          a4 quattro
                                                    6 manual(m5)
   8
                                      2.8
                                          1999
##
   9
             audi
                          a6 quattro
                                      2.8
                                           1999
                                                       auto(15)
## 10
        chevrolet c1500 suburban 2wd
                                                       auto(14)
                                      5.7 1999
                                                                    r
  # ... with 107 more rows, and 4 more variables: cty <int>, hwy <int>,
## #
      fl <chr>, class <chr>
```

filter()

```
manufac_japan <- c("honda", "toyota", "nissan")

mpg_japan <- mpg %>%
  filter(manufacturer %in% manufac_japan)

print(mpg_japan)
```

```
## # A tibble: 56 x 11
##
     manufacturer model displ year
                                     cvl trans
                                                     drv
                                                           cty
                                                                 hwy
##
            <chr>
                  <chr> <dbl> <int> <int>
                                          <chr> <chr> <int> <int>
##
   1
            honda civic
                         1.6 1999
                                       4 manual(m5)
                                                       f
                                                            28
                                                                  33
##
            honda civic
                        1.6 1999
                                           auto(14)
                                                            24
                                                                  32
##
            honda civic
                        1.6
                              1999
                                       4 manual(m5)
                                                            25
                                                                  32
##
            honda civic
                         1.6
                              1999
                                       4 manual(m5)
                                                            23
                                                                  29
##
   5
            honda civic
                                           auto(14)
                                                            24
                                                                  32
                          1.6
                              1999
##
            honda civic
                          1.8
                               2008
                                       4 manual(m5)
                                                            26
                                                                  34
##
            honda civic
                         1.8
                              2008
                                           auto(15)
                                                            25
                                                                  36
                                                            24
##
            honda civic
                         1.8
                              2008
                                           auto(15)
                                                       f
                                                                  36
##
            honda civic
                          2.0
                                       4 manual(m6)
                                                            21
                                                                  29
                               2008
```

arrange()

```
arrange(mpg, hwy)
```

arrange(mpg, desc(year))

```
## # A tibble: 234 x 11
##
      manufacturer
                                 model displ year
                                                      cyl
                                                               trans
                                                                        drv
##
             <chr>
                                 <chr> <dbl> <int> <int>
                                                               <chr> <chr>
              audi
                                          2.0
                                               2008
                                                        4 manual(m6)
    1
                                    a4
                                                                          f
##
              audi
                                               2008
                                     a4
                                          2.0
                                                             auto(av)
                                                                          f
##
              audi
                                          3.1
                                               2008
                                                             auto(av)
                                                                          f
                                     a4
##
              audi
                            a4 quattro
                                          2.0
                                               2008
                                                        4 manual(m6)
##
              audi
                            a4 quattro
                                          2.0
                                               2008
    5
                                                            auto(s6)
##
              audi
                            a4 quattro
                                               2008
                                          3.1
                                                             auto(s6)
##
              audi
                            a4 quattro
                                          3.1
                                               2008
                                                        6 manual(m6)
                                                                          4
##
              audi
                            a6 quattro
                                          3.1
                                               2008
                                                            auto(s6)
##
    9
              audi
                            a6 quattro
                                          4.2
                                               2008
                                                             auto(s6)
                                                                          4
##
  10
         chevrolet c1500 suburban 2wd
                                          5.3
                                               2008
                                                             auto(14)
                                                                          r
```

select()

```
select(mpg, manufacturer:model, year, displ, contains("y"))
```

```
## # A tibble: 234 x 7
##
      manufacturer
                        model year displ cyl
                                                   cty
##
             <chr>
                        <chr> <int> <dbl> <int> <int> <int>
##
              audi
                               1999
    1
                            a4
                                       1.8
                                                    18
                                                          29
##
              audi
                            a4 1999
                                      1.8
                                                    21
                                                          29
##
    3
              audi
                           a4
                               2008
                                      2.0
                                                    20
                                                          31
##
    4
              audi
                            a4
                               2008
                                      2.0
                                                    21
                                                          30
##
    5
              audi
                            a4 1999
                                      2.8
                                               6
                                                    16
                                                          26
##
              audi
                            a4
                               1999
                                       2.8
                                                    18
                                                          26
##
              audi
                               2008
                                       3.1
                                               6
                                                    18
                                                          2.7
                            a4
##
              audi a4 quattro
                               1999
                                      1.8
                                                    18
                                                          26
##
    9
              audi a4 quattro
                              1999
                                       1.8
                                                    16
                                                          25
## 10
              audi a4 quattro
                               2008
                                                    20
                                                          28
                                       2.0
                                               4
## # ... with 224 more rows
```

mutate()

mutate()

```
glimpse(mpg_edt)
```

```
## Observations: 234
## Variables: 7
## $ manufacturer <chr> "audi", "aud
```

summarize()

```
## # A tibble: 15 x 3
##
     manufacturer gallons avg models
##
            <chr>
                       <dbl> <int>
## 1
            honda
                   28.50000
## 2
       volkswagen
                   25.07407
##
          hyundai
                   22.75000
##
           subaru
                    22,42857
##
            audi
                   22.02778
         toyota
##
                   21.72059
          pontiac
                    21.70000
##
```

7. Workshop

· Find opgaverne i 02_opgaver.pdf på GitHub

8. Vigtigste pointer fra i dag

- ggplot() som tager tre argumenter: data + mapping + lag
- filter()
- arrange()
- select()
- mutate()
- · summarize()
- group_by()

9. Næste gang

- · Indhold:
 - R Workshop II: Import, tidy, transform
- · Pensum:
 - R4DS: kap 9 13
 - CS: Data import
- DataCamp:
 - Cleaning data in R
 - Data manipulation in R with dplyr
 - Joining data in R with dplyr
- · Supplerende:
 - R4DS: kap 14 16
 - Spachtholz (2017)